Universidad Politécnica de Chiapas

Licenciatura en Ingeniería en Tecnologías de la Información e Innovación Digital

Base de datos en la nube

Análisis comparativo del rendimiento de MongoDB y PostgreSQL JSONB bajo restricciones de CPU y memoria en agregaciones de documentos JSON anidados

Informe académico parcial

Estudiante: Jesel Moreno Zuniga
Grupo: 7B
Profesor: Horacio Irán Solís Cisneros
Actividad: 2026.C3.EVA02

1 de noviembre de 2026

La matriz prevista comprende 108 ejecuciones. El responsable confirma dos mediciones definitivas elegibles. El documento distingue la evidencia cotejada localmente, la información comunicada y los pendientes.

Resumen

Se estudia el comportamiento de MongoDB y PostgreSQL JSONB en agregaciones sobre 500 000 documentos JSON anidados. El diseño incluye tres perfiles de CPU y memoria, dos consultas, tres concurrencias y tres repeticiones, para 108 ejecuciones previstas en la matriz base. El protocolo establece calentamiento de 60 segundos, medición de 300 segundos y enfriamiento de 60 segundos.

El responsable confirma dos mediciones definitivas elegibles para Q1, perfil A, concurrencia 1 y repetición 1. Las tablas documentan su cotejo contra CSV y archivos de commit existentes. Se registran throughput, percentiles, CPU throttling, RSS máximo, spill y estado de ejecución, sin completar datos ausentes con cero.

El alcance es descriptivo: una observación por motor no permite inferir variación entre repeticiones, efectos de concurrencia o superioridad general. Se conserva la limitación del índice textual de PostgreSQL frente al cast temporal de Q2. También se documenta que la reutilización del preflight se bloqueó al cambiar de motor, sin atribuir un ahorro de tiempo no demostrado.

Palabras clave: MongoDB, JSONB, agregaciones, cgroups v2, latencia, RSS, throttling, reproducibilidad.

Índice

Introducción y justificación **3**

1. Especificaciones del host, Docker y observabilidad **3**

1.1. Equipo y sistema operativo 3
1.2. Arquitectura y servicios 4
1.3. Perfiles de recursos 4
1.4. Observabilidad y unidades 4

2. Metodología y baseline **5**

2.1. Preguntas de investigación M1/M2/M3 5
2.2. Generación 5
2.3. Carga y equivalencia 6
2.4. Índices y aceptación 6
2.5. Consultas 6
2.6. Variantes, matriz y protocolo 7
2.7. Cachés y secuencia 8
2.8. Preflight e incidencia 8
2.9. Contrato 8

3. Resultados consolidados **8**

3.1. Cobertura y procedencia 8
3.2. Valores originales 9
3.3. Resumen comunicado 10

3.4. Comparación descriptiva 10
3.5. Pilotos y pendientes 10

4. Análisis gráfico **11**

5. Planes de ejecución **13**
5.1. Escaneos y cardinalidades 13
5.2. Agregación y buffers 13
5.3. Límites de atribución 13

6. Interpretación y amenazas a la validez **13**
6.1. Alcance 13
6.2. CPU 13
6.3. Memoria 14
6.4. Spill 14
6.5. Índices y semántica 14
6.6. Amenazas 14

7. Recomendaciones para la nube **14**
7.1. Dimensionamiento 15
7.2. Concurrencia y escalabilidad 15
7.3. Selección del motor 15
7.4. Memoria y almacenamiento 15
7.5. Observabilidad 15

Conclusiones **15**

Referencias **17**

A. Reproducibilidad y auditoría **17**

B. Extractos documentales **17**

Introducción y justificación

El soporte JSON en sistemas relacionales y las bases orientadas a documentos permiten formular agregaciones sobre estructuras similares. Sin embargo, la equivalencia funcional no implica igualdad de planes, representación física o administración de memoria. Una comparación defendible requiere conservar la fuente de datos, la semántica y las condiciones que explican cada observación.

Este trabajo examina dos cargas: desanidado y agrupamiento de ítems, y filtrado temporal con ordenamiento y Top-K. La restricción explícita de CPU y memoria permite plantear preguntas sobre capacidad, latencia y trabajo temporal, sin asumir que una sola cifra representa todo el comportamiento de un motor.

La entrega es parcial. Las operaciones ejecutadas dentro de una ventana no son repeticiones independientes del escenario. Los pilotos previos, las mediciones definitivas y los escenarios pendientes deben mantenerse separados. Se distinguen hechos comunicados por el responsable, archivos examinados durante la generación y limitaciones pendientes.

Objetivo general. Comparar MongoDB y PostgreSQL JSONB mediante agregaciones sobre 500 000 documentos anidados bajo cuotas de CPU y memoria controladas.

Objetivos específicos. Verificar equivalencia de datos; conservar consultas originales; medir rendimiento y señales de recursos; describir índices y planes existentes; y delimitar el alcance de las conclusiones de una matriz incompleta.

1. Especificaciones del host, Docker y observabilidad

1.1. Equipo y sistema operativo

Campo observado al generar	Valor
captura_utc	2026-11-02T05:07:47.226454+00:00
arquitectura	x86_64
kernel	7.0.0-38-generic
CPU_logicas_visibles	16
sistema_operativo	Ubuntu 24.04.5 LTS
modelo_CPU	AMD Ryzen 7 5700X 8-Core Processor
RAM_total_host_MiB	32014.72
interfaz_cgroups_v2_presente	True
controladores	cpuset cpu io memory hugetlb pids rdma misc dmem

La captura corresponde al momento de generación del informe. Aunque se realice en el equipo experimental, no demuestra la frecuencia, disponibilidad de memoria o carga exacta durante las mediciones. Las CPU lógicas visibles no deben confundirse con núcleos físicos.

El entorno comunicado utiliza Kubuntu nativo, Docker Engine y Compose, con cgroups v2. Las versiones comunicadas son MongoDB 9.0.4 y PostgreSQL 18.6. Una etiqueta de imagen, una versión de biblioteca y la versión del servidor son evidencias diferentes. Debe cotejarse esa correspondencia con los artefactos de la cohorte.

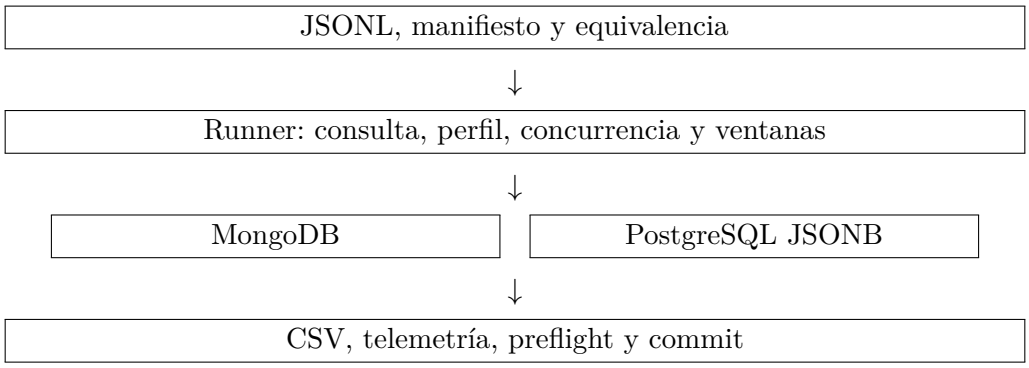
1.2. Arquitectura y servicios

Imágenes declaradas en Docker Compose.

- Imagen 1: `mongo:9.0.4-resolute`, SHA-256: `714cc3db1e39...`.
- Imagen 2: `postgres:18.6-bookworm`, SHA-256: `5c4783a8cc3f...`.

Los identificadores completos se conservan en `docker-compose.yml` y en los archivos de evidencia. Los servicios e imágenes se extraen de archivos Compose existentes. Son configuración declarada, no comprobación de salud, persistencia o límites efectivos. El generador no invoca Docker.

El esquema describe responsabilidades conceptuales y no una topología de red inferida.



1.3. Perfiles de recursos

Tabla 2: Perfiles oficiales comunicados.

Perfil	CPU	Memoria (MiB)
`PROFILE_A_BASELINE`	4	4096
`PROFILE_B_MEDIUM`	2	2048
`PROFILE_C_SEVERE`	1	1024

Docker y cgroups permiten imponer restricciones [6, 7]. Una cuota equivalente a cuatro CPU no acredita reserva de cuatro núcleos ni exclusividad. La presencia de cgroups v2 tampoco sustituye los límites efectivos del cgroup de cada motor.

El límite de memoria no es RSS máximo. La ausencia de swap no equivale automáticamente al cumplimiento literal de otra opción de swappiness; las adaptaciones requieren registro.

1.4. Observabilidad y unidades

La arquitectura comunicada utiliza Prometheus, cAdvisor y Node Exporter. La interpretación exige identificar contenedor, etiquetas, intervalo y ventana. Una serie vacía no equivale a cero. Los contadores requieren deltas y control de resets.

RSS, working set y uso total del cgroup son señales distintas. La columna se llama `max_rss_mb`, mientras que la comunicación reciente usa MiB. Se conservan valores originales, sin convertir ni renombrar la unidad silenciosamente. La fórmula del recolector y su correspondencia con la cohorte deben cotejarse.

2. Metodología y baseline

2.1. Preguntas de investigación M1/M2/M3

Las preguntas de lectura se refieren a rendimiento, recursos y comportamiento bajo concurrencia. La identificación normativa M1/M2/M3 debe conservar la formulación de los playbooks. Los extractos reconocidos se presentan sin inventar una correspondencia.

Preguntas de investigación del manual

M1. ¿Cómo cambian la latencia P95 y P99 de las agregaciones sobre documentos anidados cuando se limita de forma estricta la CPU y la memoria?

M2. ¿Qué motor usa de forma más eficiente los buffers de ordenamiento y agrupamiento antes de volcar a disco temporal o fallar por falta de memoria (OOM)?

M3. ¿Cuál es la huella de CPU y memoria por cada 1 000 documentos procesados en el motor documental frente al motor con JSONB?

Fuentes: playbook.pdf, página 1; playbook_sesion.pdf, página 4.

2.2. Generación

El responsable confirma 500 000 documentos, semilla 42 y 1 499 443 ítems, aproximadamente tres por orden. La estructura incluye órdenes, clientes, ubicaciones, productos, pagos y metadatos. El desanidado produce una cardinalidad intermedia distinta del número de documentos.

La semilla favorece repetibilidad, pero también importan generador y dependencias. Por ello se conservan manifiesto y hashes. Las distribuciones no se deducen de una descripción general.

SHA-256 comunicado del JSONL:

9fecf656a02cf6d369517ae4d59f47072e4de4025ae9db6280611347fb557afb

Hash lógico comunicado:

3490c8c2b9a58f58ee69849dd55f00d556e64456168964d0cf74262e95cc7715

Fuente o campo leído	Valor
data/orders-42.jsonl.manifest.json	SHA-256: b86997e6e6266917240a8b82e644805e c4ebe4698798fa2f2d3b8b0f3d421fe0
configuration.seed	42
item_count	1499443
sha256	`9fecf656a02cf6d369517ae4d59f4707 2e4de4025ae9db6280611347fb557afb`
data/equivalence-42.json	SHA-256: 17750f290994e1e7ec84049ea634d796 61e8ca9dfa352edb8280c7fb12b0b3cc
status	ok

2.3. Carga y equivalencia

Se comunican 500 000 documentos importados en cada motor y equivalencia lógica completa PASS. No implica igualdad binaria entre JSONL, BSON y JSONB ni igualdad de espacio físico.

La igualdad de documentos no sustituye validar resultados de Q1/Q2. Tipos, fechas, orden y empates requieren los controles del proyecto. Importación y equivalencia son precondiciones, no resultados de rendimiento.

2.4. Índices y aceptación

MongoDB dispone, según el responsable, de `_id` y de índices simples en `timestamp` y `order_id`. PostgreSQL tiene PRIMARY KEY en `id` y B-Tree textual en `data»'timestamp'`.

Q2 convierte ese texto a `timestamptz`. Se distinguen:

1. existencia, definición y validez física;
2. compatibilidad con el predicado;
3. utilización efectiva en un plan;
4. aprobación académica.

La expresión consultada importa para un índice sobre expresiones [3]. La aceptación del responsable no demuestra uso, compatibilidad con el cast ni aprobación del profesor. La limitación permanece aunque las mediciones actuales sean Q1.

2.5. Consultas

Q1 desanida ítems, filtra `price >50`, calcula subtotales y agrupa por país y categoría, produciendo sumatoria, promedio y conteo. Deben mantenerse expresiones y tipos originales.

Q2 selecciona órdenes completadas en un rango temporal, ordena por importe final descendente y recupera Top-1000. No hay resultados definitivos Q2 incorporados.

Los extractos proceden de archivos reales y se conservan fuentes completas. La selección automática no acredita por sí sola su invocación por el runner.

Fuente original: queries/mongodb/q1.json, líneas 1–10 Se conserva la fuente completa como recurso editable. El extracto visual muestra hasta 48 líneas y representa caracteres fuera de ASCII mediante escapes Unicode.

```
[
  {"$unwind": "$items"},
  {"$match": {"items.price": {"$gt": 50}}},
  {"$group": {
    "_id": {"country": "$customer.geo.country", "category": "$items.category"},
    "total_revenue": {"$sum": {"$multiply": ["$items.qty", "$items.price"]}},
    "avg_revenue": {"$avg": {"$multiply": ["$items.qty", "$items.price"]}},
    "count": {"$sum": 1}
  }}
]
```

Fuente original: queries/mongodb/q2.json, líneas 1–6 Se conserva la fuente completa como recurso editable. El extracto visual muestra hasta 48 líneas y representa caracteres fuera de ASCII mediante escapes Unicode.

```
[
  {"$match": {"payment.status": "completed", "timestamp": {"$gte": "2026-01-01T00:00:00Z"}}},
  {"$sort": {"payment.final_total": -1}},
  {"$limit": 1000},
  {"$project": {"order_id": 1, "customer.id": 1, "payment.final_total": 1}}
]
```

Fuente original: queries/postgresql/q1.sql, líneas 1–8 Se conserva la fuente completa como recurso editable. El extracto visual muestra hasta 48 líneas y representa caracteres fuera de ASCII mediante escapes Unicode.

```
SELECT data->'customer'->'geo'->>'country' AS country,
       item->>'category' AS category,
       SUM((item->>'qty')::numeric * (item->>'price')::numeric) AS total_revenue,
       AVG((item->>'qty')::numeric * (item->>'price')::numeric) AS avg_revenue,
       COUNT(*) AS count
FROM orders, jsonb_array_elements(data->'items') AS item
WHERE (item->>'price')::numeric > 50
GROUP BY 1, 2;
```

Fuente original: queries/postgresql/q2.sql, líneas 1–8 Se conserva la fuente completa como recurso editable. El extracto visual muestra hasta 48 líneas y representa caracteres fuera de ASCII mediante escapes Unicode.

```
SELECT data->>'order_id' AS order_id,
       data->'customer'->>'id' AS customer_id,
       (data->'payment'->>'final_total')::numeric AS final_total
FROM orders
WHERE data->'payment'->>'status' = 'completed'
  AND (data->>'timestamp')::timestamptz >= '2026-01-01 00:00:00Z'
ORDER BY (data->'payment'->>'final_total')::numeric DESC
LIMIT 1000;
```

2.6. Variantes, matriz y protocolo

La matriz base selecciona `allow_disk_false` y `work_mem_4mb`. Las variantes `allow_disk_true` y `work_mem_64mb` se mantienen separadas. No son presupuestos internos equivalentes de memoria.

El diseño comprende:

$$3 \text{ perfiles} \times 2 \text{ motores} \times 2 \text{ consultas} \times 3 \text{ concurrencias} \times 3 \text{ repeticiones} = 108.$$

Las concurrencias son 1, 10 y 50. Una repetición por escenario comprende 36 ejecuciones y no completa el protocolo.

Se establecen 60 s de warmup, 300 s de medición y 60 s de cooldown. La duración total incluye preparación y controles: los 53 minutos y 38 segundos comunicados para PostgreSQL no sustituyen la ventana ni se usan como denominador de QPS.

Debe conservarse el criterio del runner sobre operaciones en los límites de ventana. No se reconstruye la latencia media desde la inversa de QPS ni se inventa conteo de operaciones.

2.7. Cachés y secuencia

El warmup no acredita estabilización. Caché del motor, caché del sistema operativo y conexiones son controles distintos. Un comando en un script no demuestra que se ejecutara en cada repetición.

Este generador no limpia cachés, reinicia servicios ni ejecuta operaciones privilegiadas. Las condiciones deben cotejarse con evidencia existente.

2.8. Preflight e incidencia

El responsable confirma 135 pruebas automatizadas aprobadas para la optimización. La reutilización se bloqueó al cambiar de motor. Los casos probados y el intento de reutilización son evidencias distintas.

No hay comparación temporal válida antes/después. No se afirma ahorro experimental. Se registra la incidencia sin modificar resultados comprometidos ni suprimir controles.

2.9. Contrato

La cabecera conserva 14 columnas:

```
timestamp_epoch,engine,profile,query_id,concurrency,run_number,throughput_qps,latency_p50_ms,latency_p95_ms,
    latency_p99_ms,cpu_throttled_seconds,max_rss_mb,disk_spill,status
```

`spill` puede coexistir con elegibilidad. Las ausencias no se completan con cero. La confirmación del responsable se distingue del reconocimiento automático de campos en las evidencias.

3. Resultados consolidados

3.1. Cobertura y procedencia

El responsable confirma dos mediciones elegibles Q1/A/C1/R1, una por motor. La cobertura y el cotejo local se distinguen.

Concepto	Cantidad
Ejecuciones planificadas	108
Mediciones elegibles confirmadas por el responsable	2
Filas cotejadas y admitidas por el generador	2
Repeticiones restantes sin resultado elegible comunicado	106

Elemento	Procedencia
MongoDB: CSV	results/definitive/definitivo-q1-perfil-a-optimizado-20261101/4f537e29c5c322d57cebb3b9/attempt-49fe681fa4fc4261b69ac54edfe44904/results.csv
Fila de datos	1
SHA-256 CSV	`342f7f78041e3c865922c50b5832e24ece8ed8d8a388f0499dad5e8cf92975bb`

Elemento	Procedencia
Commit	results/definitive/definitivo-q1-perfil-a-optimizado-20261101/4f537e29c5c322d57cebb3b9/attempt-49fe681fa4fc4261b69ac54edfe44904/commit.json
SHA-256 commit	`a0b2d4197e15b260a338aa86d9d8d7684456edd1 5d0343817c237216405d030a`
Hash CSV reconocido en commit	Sí
Elegibilidad	Campo local y confirmación explícita del responsable
PostgreSQL: CSV	results/definitive/definitivo-pg-q1-a-c1-20261101-v2/bc0a8de32c1719c76fca6946/attempt-708f060a15574a85b9c78a57ae8113f0/results.csv
Fila de datos	1
SHA-256 CSV	`eb98ccb0f77d4fd52f07a8ef6502d0a553e65a60 6ba091269bfb7cfafacb66de`
Commit	results/definitive/definitivo-pg-q1-a-c1-20261101-v2/bc0a8de32c1719c76fca6946/attempt-708f060a15574a85b9c78a57ae8113f0/commit.json
SHA-256 commit	`29379f16eb19f2579700f717f74b251b9ddc4b25 28a3f79b9e2c4b67b80b8acf`
Hash CSV reconocido en commit	Sí
Elegibilidad	Campo local y confirmación explícita del responsable

La asociación de CSV y commit por directorio no se presenta como verificación criptográfica cuando no se reconoce el hash correspondiente.

3.2. Valores originales

Las tablas conservan los decimales del CSV y no se corrigen para coincidir con un resumen redondeado.

MongoDB: Q1/A/C1/R1

Métrica	Valor original
Throughput (QPS)	0.54666666666666666666666666667
P50 (ms)	1818.4072985
P95 (ms)	1861.30314085
P99 (ms)	1902.25359347
CPU throttling (s)	0
RSS: columna max_rss_mb	1026.650112
Disk spill	0
Estado	ok
Timestamp epoch original	1793591113.03612191

PostgreSQL: Q1/A/C1/R1

Métrica	Valor original
Throughput (QPS)	0.41666666666666666666666666667
P50 (ms)	2353.831192
P95 (ms)	2562.6225742
P99 (ms)	2800.77333032
CPU throttling (s)	0.083895
RSS: columna max_rss_mb	108.224512
Disk spill	1
Estado	spill
Timestamp epoch original	1793585428.81335425

Spill no cuantifica bytes o número de volcados. El throttling positivo es una señal de la ventana, no una explicación causal completa.

3.3. Resumen comunicado

Tabla 8: Cifras comunicadas y redondeadas; no son nuevas mediciones.

Métrica	MongoDB	PostgreSQL
QPS	0.5467	0.4167
P50 (ms)	1818.41	2353.83
P95 (ms)	1861.30	2562.62
P99 (ms)	1902.25	2800.77
RSS comunicado como MiB	1026.65	108.22
Throttling (s)	0	0.083895
Spill	0	1
Consultas completadas comunicadas	164	125

Los conteos se identifican como comunicados, sin deducirlos de QPS. La unidad RSS debe reconciliarse con el recolector.

3.4. Comparación descriptiva

En las ventanas leídas, el throughput de MongoDB fue 31.20 % mayor que PostgreSQL. El cociente P99 PostgreSQL/MongoDB fue 1.472. Son cocientes descriptivos individuales, no estimaciones poblacionales ni evidencia causal. Cada motor aporta una observación. Las operaciones comparten condiciones y no son réplicas independientes. No se presentan pruebas de significancia o intervalos no sustentados.

3.5. Pilotos y pendientes

Los pilotos de 15 segundos precedieron a los índices secundarios completos. Se mantienen como exploración de funcionamiento y telemetría.

No se incorporan Q2, B/C ni C10/C50. Las otras 106 repeticiones no tienen resultado elegible comunicado en esta entrega. Pendiente, bloqueada e incompleta son estados distintos que requieren registros reales.

4. Análisis gráfico

Las figuras usan valores leídos de los CSV admitidos. No completan escenarios ni introducen ajustes o intervalos ficticios. P50, P95 y P99 son resúmenes de una ventana, no tres réplicas. Un máximo no

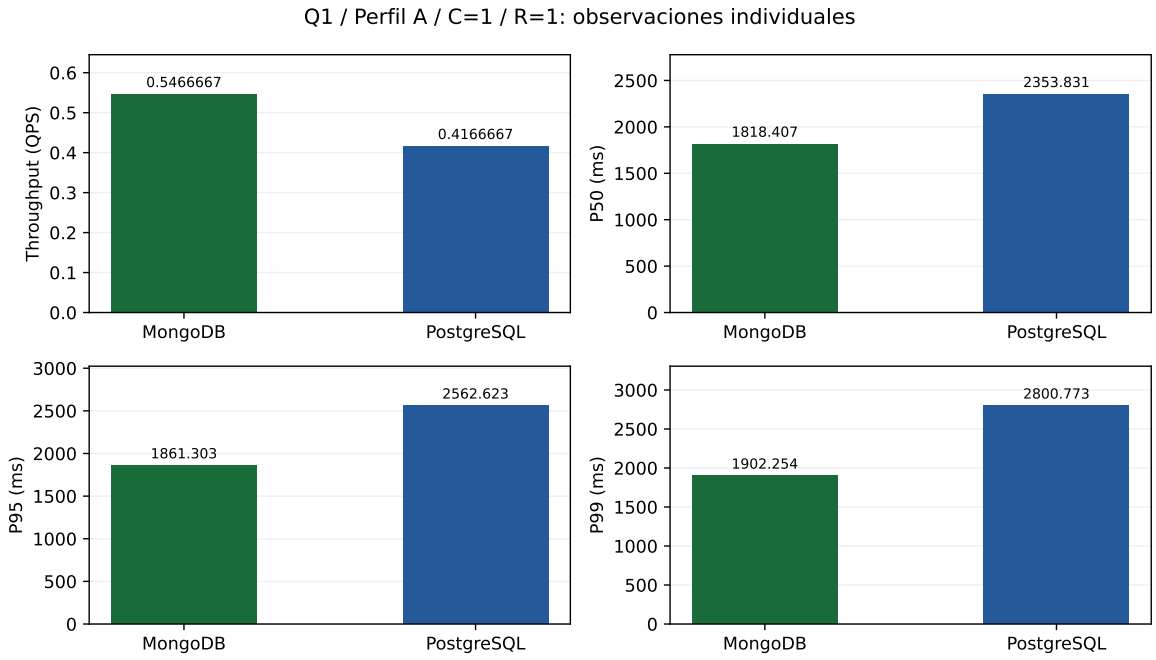


Figura 1: Throughput y percentiles individuales Q1/A/C1/R1. No son promedios entre repeticiones.

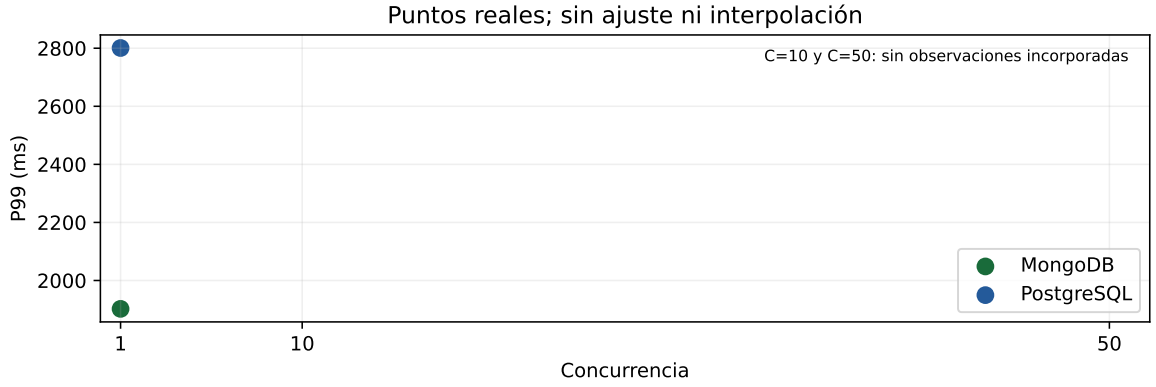


Figura 2: P99 frente a concurrencia. Solo C=1 tiene observaciones.

reconstruye evolución temporal. Las series se incluyen solo si existen muestras e identidad suficiente. Su intervalo no se equipara automáticamente con la ventana de medición.

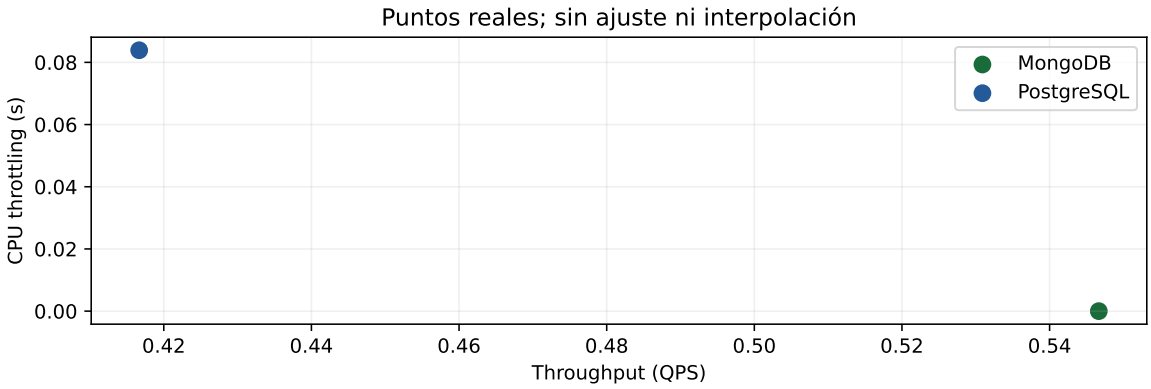


Figura 3: Throttling frente a QPS. Dos puntos no sustentan una relación causal.

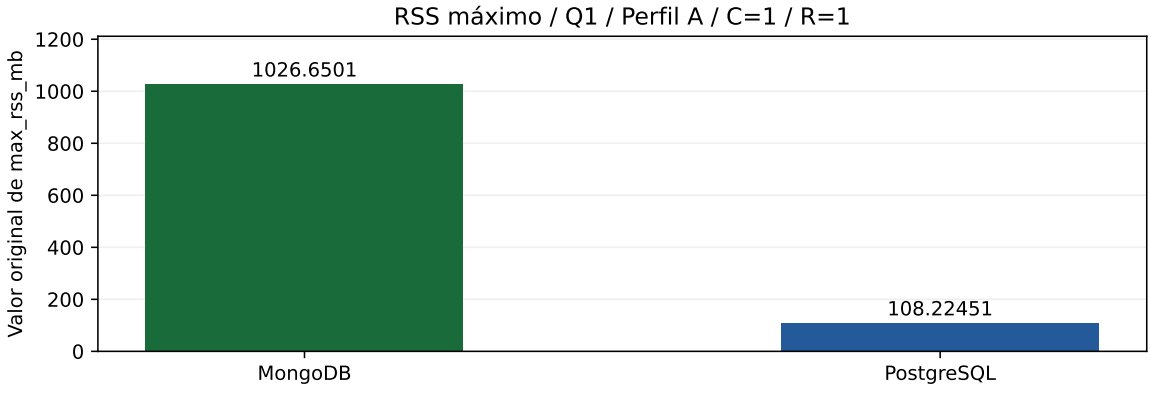


Figura 4: RSS máximo original. No se convierte MB a MiB sin cotejar el recolector.

Pendiente: No se reconoció una serie RSS con identidad suficiente.

5. Planes de ejecución

La evidencia prevista es `explain(.ᵉˣecutionStats")` y `EXPLAIN (ANALYZE, BUFFERS)`. Solo se utilizan artefactos existentes; no se ejecutan consultas para completarlos.

Pendiente: No se reconocieron planes ejecutados. No se ejecutaron consultas para generarlos. Revisar posibles planes de texto u otros formatos.

5.1. Escaneos y cardinalidades

Escaneo secuencial, índice y filtro representan trabajo distinto. Filas estimadas y reales, loops y cardinalidades intermedias aportan contexto. La existencia del índice no acredita su elección.

En Q1 desanidar puede ampliar el flujo hacia filtro y agregación. El total de ítems no determina grupos ni costo del operador. En Q2 la selectividad condiciona el ordenamiento sin demostrar una ruta específica.

5.2. Agregación y buffers

En PostgreSQL, método de ordenamiento y bloques temporales describen el plan cuando están presentes. Buffers no son RSS y costos estimados no son tiempos observados [2]. Ausencia de campo no significa cero.

En MongoDB, documentos y claves examinados describen acceso. No se atribuyen etapas ausentes ni se trasladan campos entre versiones.

5.3. Límites de atribución

Un EXPLAIN adicional ejecuta su propio trabajo y no completa spill de otra ventana. El estado CSV no identifica operador ni tamaño temporal. Un plan Q1 no demuestra Q2 o uso del índice para el cast temporal.

6. Interpretación y amenazas a la validez

6.1. Alcance

Q1/A/C1/R1 no permite generalizar a otros perfiles, concurrencias o consultas. Las operaciones comparten procesos y cachés, de modo que no reemplazan repeticiones independientes.

Promediar percentiles no produce un percentil global. La inversa de QPS no sustituye necesariamente la latencia media, por los límites y criterios de contabilización.

6.2. CPU

PostgreSQL comunica 0.083895 segundos de throttling y MongoDB cero. La señal positiva no demuestra que CPU explique la diferencia temporal. Cero no excluye espera de E/S u otros cuellos de botella.

La cuota define capacidad permitida y no uso constante. Sin B/C ni C10/C50 no se caracteriza respuesta a cuotas menores o saturación.

6.3. Memoria

RSS exige revisar alcance y unidades. No representa automáticamente toda la memoria atribuible: memoria compartida, procesos y caché del host pueden tener coberturas diferentes.

PostgreSQL distingue buffers compartidos de memoria de operaciones. `work_mem` no es un límite global y puede multiplicarse con sesiones y operaciones [1]. WiredTiger mantiene caché propia e interactúa con la caché del sistema de archivos [4]. Estas explicaciones no atribuyen por sí solas el RSS de las ventanas.

No se afirman tamaños internos sin configuración ni se suman señales heterogéneas para fabricar una memoria total.

6.4. Spill

Las políticas y planes diferentes son explicaciones posibles del spill, pero no demuestran causalidad. Se requiere evidencia del operador y de la ventana para cuantificar trabajo temporal.

El permiso de disco de MongoDB condiciona etapas, sin obligarlas a derramar [5]. No equivale a `work_mem`. Las variantes se analizan separadamente.

6.5. Índices y semántica

La aceptación del responsable no transforma un índice textual en temporal. La elegibilidad Q1 no demuestra la ruta de Q2. La equivalencia lógica no obliga a estructuras internas iguales.

6.6. Amenazas

- **Interna:** orden, cachés, carga, límites, ventanas y resets.
- **Constructo:** unidad RSS, spill, cálculo de QPS y errores.
- **Comparación:** variantes, índices, versiones y planes.
- **Externa:** un host, una semilla y dos consultas.
- **Conclusión:** una repetición por motor no estima variabilidad.

Las 135 pruebas del preflight no son medición de ahorro temporal. El bloqueo al cambiar de motor permanece como incidencia operativa.

7. Recomendaciones para la nube

Son criterios generales, no selección validada de proveedor o instancia.

7.1. Dimensionamiento

CPU y memoria deben contrastarse con throughput requerido, latencia, estados y margen. Cuotas locales no equivalen automáticamente a vCPU dedicadas, créditos o almacenamiento remoto.

RSS individual no define un mínimo seguro. No se recomienda reducir memoria hasta el máximo observado ni aumentar CPU solo por throttling. Deben contemplarse concurrencia, cachés y trabajo temporal.

7.2. Concurrencia y escalabilidad

Más clientes podrían aumentar colas sin mejorar QPS, pero no está demostrado aquí. C10/C50 no reciben recomendaciones cuantitativas.

Escalar horizontalmente introduce coordinación, red y consistencia. Los beneficios no se deducen de un contenedor local por motor.

7.3. Selección del motor

Q1 no representa toda la aplicación. Importan transacciones, escrituras, modelo de datos, índices y operación. Dos observaciones no establecen un ganador general. Q2 requiere evaluación y exposición de la limitación del índice textual.

7.4. Memoria y almacenamiento

La memoria por operación debe revisarse con sesiones, límite del contenedor y almacenamiento temporal. Aumentar parámetros puede trasladar presión desde disco a memoria. Spill no implica automáticamente fallo; su ausencia tampoco garantiza una ejecución óptima.

7.5. Observabilidad

Deben conservarse identificadores, commit, consultas, variantes, límites y cobertura. Los paneles deben distinguir ausencia de datos y cero. La reutilización del preflight requiere contexto compatible; su bloqueo no permite afirmar ahorro demostrado.

Conclusiones

La importación de 500 000 documentos y equivalencia completa son controles de preparación, no resultados de rendimiento.

La entrega se limita a dos mediciones comunicadas Q1/A/C1/R1, con cotejo local y sus límites registrados por separado. No representa 108 ejecuciones.

MongoDB comunica mayor QPS y menores percentiles; PostgreSQL comunica menor RSS, throttling positivo y spill. No establecen superioridad general ni causalidad. RSS requiere reconciliar unidad y alcance.

No se incorporan Q2, B/C ni C10/C50 ni se infieren tendencias. Los pilotos se mantienen separados. El índice textual conserva su limitación: existencia, compatibilidad, uso y aprobación son condiciones diferentes.

La optimización del preflight tiene 135 pruebas aprobadas según el responsable, pero su reutilización se bloqueó al cambiar de motor. No se atribuye ahorro temporal sin comparación válida.

Las actualizaciones deben incorporar solo evidencias reales y revisar conclusiones conforme a la cobertura efectivamente alcanzada.

Referencias

[1] PostgreSQL Global Development Group. *PostgreSQL 18: Resource Consumption*. https://www.postgresql.org/docs/18/runtime-config-resource.html.

[2] PostgreSQL Global Development Group. *PostgreSQL 18: Using EXPLAIN*. https://www.postgresql.org/docs/18/using-explain.html.

[3] PostgreSQL Global Development Group. *PostgreSQL 18: Indexes on Expressions*. https://www.postgresql.org/docs/18/indexes-expressional.html.

[4] MongoDB. *WiredTiger Storage Engine*. https://www.mongodb.com/docs/manual/core/wiredtiger/.

[5] MongoDB. *Aggregation Pipeline Limits*. https://www.mongodb.com/docs/manual/core/aggregation-pipeline-limits/.

[6] Docker. *Resource constraints*. https://docs.docker.com/engine/containers/resource_constraints/.

[7] The Linux Kernel documentation. *Control Group v2*. https://docs.kernel.org/admin-guide/cgroup-v2.html.

A. Reproducibilidad y auditoría

`auditoria.json` conserva fuentes, hashes, selección y compilación. `ESTADO_ENTREGABLE.md` identifica cumplidos y pendientes. El reporte anterior se respalda en `reports/latex-backups/`.

Se usa una carpeta nueva de recursos para evitar figuras antiguas. La asociación CSV/commit por directorio no se presenta como vínculo criptográfico si este no se reconoce. Una declaración local negativa impide admitir automáticamente la fila. La aprobación docente no se infiere.

Las fuentes originales de consultas se conservan sin cambios. Los extractos visuales pueden representar caracteres mediante escapes. Su selección no sustituye revisar las invocaciones reales del runner.

B. Extractos documentales

Son material de trazabilidad, no certificación integral de cumplimiento. Deben revisarse junto con referencias P/S y decisiones vigentes.

Documentación técnica complementaria Los documentos originales de desarrollo, decisiones y validación permanecen disponibles en el repositorio. Su consulta permite reconstruir el proceso experimental.

- `docs/07-decisiones-y-pendientes.md`: decisiones técnicas, discrepancias y asuntos pendientes.
- `docs/11-consultas-y-validacion.md`: implementación y verificación de Q1 y Q2.
- `docs/12-automatizacion-benchmarks.md`: arquitectura del runner y secuencia experimental.
- `docs/13-observabilidad-y-telemetria.md`: recolección y tratamiento de métricas.

- `docs/14-analisis-y-reporte.md`: criterios de análisis y generación de informes.

Los extractos técnicos originales se conservan como evidencia en el proyecto. No se reproducen aquí las versiones con caracteres dañados por la extracción automática de texto.